

SignNet

Sign Language Recognition System

Project Status Report

Stand: 02. December 2025

Autoren: Andrei Chirila, Roman Schläpfer

Institution: OST - Ostschweizer Fachhochschule

Dataset: RWTH-PHOENIX-Weather 2014

Architektur: Transformer Encoder + Multi-Task Learning

1. Executive Summary



Das SignNet-System erreicht eine **67.16% Top-1 Accuracy** auf 146 Gloss-Klassen aus dem RWTH-PHOENIX-Weather 2014 Dataset. Die Analyse zeigt spezifische Confusion-Cluster, die durch spezialisierte Expert-Modelle adressiert werden können.

2. Modell-Architektur

TransformerSignClassifierWithHandedness

Das Modell verwendet einen reinen Transformer-Encoder mit Multi-Task Learning für simultane Gebärden- und Händigkeitserkennung. Die Architektur verarbeitet MediaPipe-Landmarks (Hände, Gesicht, Pose) durch Self-Attention und ermöglicht variable Sequenzlängen.

Input: Landmarks (1659 features/frame)

↓

Linear Projection (1659 $\rightarrow$ 512) + Positional Encoding

↓

Transformer Encoder (6 Layers, 8 Heads, FFN: 2048)

↓

Mean Pooling (über Zeit-Dimension)

↓

XXXXXXXXXXXXXXXXXXXXXXXXXXXX

Sign Head Handedness Head

$$(512 \rightarrow 146) \quad (512 \rightarrow 4)$$

Parameter	Main Model	Expert Model
Hidden Size	512	64
Num Layers	6	2
Num Heads	8	4
FFN Dimension	2048	256
Dropout	0.60	0.50
Attention Dropout	0.30	0.30
Batch Size	256	32
Learning Rate	1e-4	3e-5

3. Evaluationsergebnisse

3.1 Accuracy nach Sample Count

Die Analyse zeigt einen deutlichen Performance-Gap zwischen Klassen mit wenigen und vielen Trainingssamples:

Stratum	Sample Range	Accuracy	Klassen	Samples	Gap
LOW	0 - 100	57.2%	35	579	-11.2%
MID	100 - 300	68.2%	88	3,178	Baseline
HIGH	300+	68.4%	23	1,900	+0.2%

3.2 Top Confused Class Pairs

Die Confusion Matrix Analyse identifiziert systematische Verwechslungen zwischen semantisch oder visuell ähnlichen Klassen:

#	True Class	→	Predicted	Errors	Rate
1	ABEND	→	NACHT	22	43.1%
2	KOMMEN	→	cl-KOMMEN	16	25.4%
3	NACHT	→	ABEND	14	13.1%
4	ZWANZIG	→	ZWEI	14	21.9%
5	HAUPTSAECHLICH	→	MEISTENS	13	59.1%
6	REGEN	→	REGEN-PLUSPLUS	13	11.2%
7	cl-KOMMEN	→	KOMMEN	13	26.0%
8	AUCH	→	ABER	12	14.8%
9	REGION	→	loc-REGION	12	20.7%
10	loc-SUEDOST	→	loc-SUED	11	45.8%

3.3 Identifizierte Confusion-Cluster

Die Confusions lassen sich in semantische Cluster gruppieren, die durch spezialisierte Expert-Modelle adressiert werden können:

Cluster	Betroffene Klassen	Fehler	Ursache
Direction	SUED, loc-SUED, loc-SUEDOST, SUEDOSTRAUM, NORDRAUM, etc.	~200	Zeigegeesten ähnlich
Numbers	ZWEI, DREI, VIER, ZWANZIG, ZEHN, FUENF, etc.	~50	Fingerformen ähnlich
Adverbs	MEISTENS, HAUPTSAECHLICH, STARK, BESONDERS	~50	Semantisch ähnlich
Kommen	KOMMEN, cl-KOMMEN, WEHEN	~30	Bewegungstrajektorien
Weather	REGEN, SCHAUER, SCHNEE, STURM, WIND	~40	Abwärtsbewegungen
Time	ABEND, NACHT, MORGEN, TAG	~20	Semantisch ähnlich

3.4 Kritische Problem-Klassen

Klassen mit F1-Score < 0.35 oder extremen Precision/Recall-Imbalancen:

Klasse	Precision	Recall	F1	Problem
SUEDRAUM	0.00	0.00	0.00	Komplett versagt → DROP
loc-SUED	0.19	0.74	0.30	Attractor (zieht alles an)
ZWEI	0.21	0.67	0.31	Attractor (Zahlen)
loc-SUEDOST	0.50	0.13	0.20	Wird fast nie predicted
UEBERWIEGEND	0.67	0.13	0.22	Niedriger Recall

4. Vorgeschlagene Verbesserungen

4.1 Implementierte Änderungen

- **DROP_CLASSES:** SUEDRAUM wird automatisch aus dem Training entfernt (F1=0)
- **7 Expert-Modelle definiert:** direction, numbers, adverb, kommen, weather, connector, time
- **Erweitertes Oversampling:** Mehr problematische Klassen werden verstärkt (loc-SUEDOST 5x, UEBERWIEGEND 5x)
- **Bug Fixes:** Vocab/val_indices werden korrekt gespeichert, torch.compile Windows-kompatibel
- **Model-Save ohne Prefix:** Checkpoints direkt in GUI ladbar

4.2 Expert Training Strategie

Priorität	Expert	Klassen	Geschätzte Fehlerreduktion
1	direction_expert	22	100-150 Fehler
2	numbers_expert	21	30-40 Fehler
3	adverb_expert	10	30-40 Fehler
4	kommen_expert	5	20-30 Fehler
5	weather_expert	9	30-40 Fehler
6	connector_expert	5	15-20 Fehler
7	time_expert	7	15-20 Fehler

4.3 Erwartete Ergebnisse

Realistisches Ziel: 67% → 72-75% nach Implementierung aller Optimierungen

Maßnahme	Erwartete Verbesserung
SUEDRAUM dropen	+0.2% (weniger Noise)
Erweitertes Oversampling	+1-2%
direction_expert	+2-3%
Alle anderen Experts	+2-3%
GESAMT	+5-8%

5. Nächste Schritte

Kurzfristig:

- Hauptmodel neu trainieren mit DROP_CLASSES und erweitertem Oversampling
- Evaluation durchführen und Baseline-Verbesserung verifizieren

Mittelfristig:

- direction_expert trainieren (höchste Priorität)
- numbers_expert und adverb_expert trainieren
- Hierarchical Inference Pipeline implementieren (Main → Expert cascade)

Langfristig:

- GUI-Integration mit Real-time Webcam Support
- Alle Expert-Modelle trainieren und integrieren
- Performance-Optimierung für 24+ FPS auf Consumer Hardware

